



**中国科学院大学**  
University of Chinese Academy of Sciences

## 研究生学位论文开题报告

报告题目 基于无人机的 GNSS/INS 算法研究与实现

学生姓名 秦闪闪 学号 201728017227002

指导教师 徐颖 职称 研究员

学位类别 工学硕士

学科专业 信号与信息处理

研究方向 组合导航

研究所（院系） 中国科学院光电研究院

填表日期 2018 年 11 月 27 日

中国科学院大学制



---

## 目 录

1. 选题的背景与意义 .....	1
2. 国内外本学科领域的发展现状与趋势 .....	3
2.1 组合导航研究现状.....	3
2.2 滤波技术研究现状.....	7
2.3 滤波理论在组合导航中的应用.....	9
3. 课题的主要研究内容和预期目标 .....	10
3.1 研究内容.....	10
3.2 预期目标.....	12
4. 拟采用的研究方法、实验方案、技术路线、可行性分析 .....	12
4.1 研究方法、实验方案.....	12
4.2 技术路线.....	21
4.3 可行性分析.....	22
5. 已有科研基础与所需的科研条件 .....	23
5.1 已有的科研基础.....	23
5.2 所需科研条件.....	23
6. 研究工作计划与进度安排 .....	23
参考文献.....	25



---

## 1. 选题的背景与意义

无人机（Unmanned Aerial Vehicle, UAV）通常指利用远程监控或自身程序控制的，可一次性使用或者重复使用的非载人飞行器。由于无人机具有体积小、质量轻、操作灵活、可在危险且复杂环境下执行任务等特点，被广泛用于军用与民用领域。在军用领域上，无人机可以进行情报侦察、跟踪定位、电子干扰、信息对抗等战略和战术任务，以达到监视战场并提供战场情报的目的。民用领域上，无人机可以深入应用于农林植保、电力巡线、石油管道巡检、国土测绘、海洋监测、气象探测、人工降雨、航空遥感、抢险救灾、环保监测、森林防火、警用巡逻、交通监控、物流快递、医疗救护、地质勘探、海洋遥感、新闻报道、野生动物保护等诸多行业场景中。

导航系统作为无人机中最重要的组成部分，为无人机提供速度、位置和姿态等信息，保障了无人机自主飞行的实现。导航技术可以分为两大类：（1）自主式导航。自主式导航是利用架设在导航载体上的设备来达成导航目的的技术，其不仅不依赖外界信息，且不向外界发射能量，所以不易收外界的干扰。典型的有惯性导航（Inertial Navigation System, INS）和多普勒导航。（2）非自主式导航。非自主式导航需要导航载体与载体外的空中或地面设备发生联系，利用两者的配合完成导航任务，其一般拥有更广阔的导航范围。典型的有无线电导航和卫星导航<sup>[1]</sup>。

组合导航则是使用两种及以上的导航系统或设备对同一个导航载体进行测量，利用不同系统的优势来校正单一导航系统中无法消除的误差，从而达到更高的导航精度。利用组合导航系统能够分别从不同的导航系统的优势中获益，并且消除子系统单独使用的不足之处，是更加精确且有效的导航手段。目前，无人机最常用的组合导航系统是全球导航卫星系统（Global Navigation Satellite System, GNSS）和惯性导航系统组合。

惯性导航是依据惯性空间中的力学定律来进行导航的系统，其在导航载体初始位置已知的情况下，利用加速度计和陀螺仪这类敏感元件测量载体的角速度和

---

加速度，再通过坐标系变换，在一定坐标系中对测量数据进行积分，从而得到载体的瞬时速度和位置信息。惯性导航的设备都安装在载体之内，其工作不依赖外界信息，且不对外辐射能量，所以不受到外界的干扰，能够自主地进行工作。但其工作误差会随着时间而进行积累，最终导致系统导航解不可信。为了克服这一缺点，单独使用惯性导航的系统会采用更高精度的惯性测量元件，但随着而来的是成本和重量的大幅上升<sup>[2]</sup>，不仅使用成本提高，而且在类似于无人机这样载荷较小的导航载体上难以使用。

卫星导航是利用运行在地球上空轨道上的卫星来对处于地球的导航载体提供服务的系统，其能够提供高精度的覆盖全球的三维位置信息。但其在导航载体动态性高时容易失锁，在短期导航下性能比较差，且由于其较低的信息更新率，在对实时性要求高的场合难以达到预期的效果。另外，其在都市峡谷等遮挡物较多的地方信号受干扰严重，甚至会出现完全没有信号的情况。

上面两种导航系统都有其单独使用时难以克服的缺点，然而他们却有着较强的互补性，将惯性导航系统的短期高精度特性和卫星导航系统的长期稳定性特性结合能够得到比单独一个系统更高的精度和更好的稳定性。由于惯性导航和卫星导航都能提供完整的导航解，惯性导航能够通过卫星导航信息修正自己的测量数据，卫星导航也能借助惯性导航的位置和速度信息辅助来改善自己捕获和跟踪的能力。除此之外，两者组合可以在天气条件不好，卫星可见度差或者难以接受到足够数量的卫星时不失去其导航能力。

惯性导航和卫星导航相结合的导航手段，即 GNSS/INS，在近些年获得广泛关注，其原因在于现今很多如侦察等任务对导航精度提出了更高的要求，现代控制技术及卡尔曼滤波的研究提供了理论基础和数学工具，以及，数字计算机的快速发展降低了其计算成本<sup>[1]</sup>。如今 GNSS/INS 已经发展地比较成熟，各种方法在不同领域取得的实际可用的结果。然而，在森林峡谷中，GNSS 信号因被遮挡或干扰而出现的短时缺失的情况，INS 的误差因没有外部输入的校正，其误差不断积累，从而导致其精度下降，影响组合导航系统的性能。

无人机由于其高动态特性，极易出现 GNSS 失锁现象。本课题针对这一问题，提出一种无人机 GNSS/INS 组合导航的数据融合算法——深度卡尔曼滤波。具体

---

来说,本课题在卡尔曼滤波的预测和更新步骤中添加了建模步骤,以便在集成过程中学习 IMU 误差模型,希望能够在 GNSS 失锁时保证无人机的导航精度。

## 2. 国内外本学科领域的发展现状与趋势

### 2.1 组合导航研究现状

GNSS/INS 组合导航系统的研究在上世纪就展开了,其子系统一般定位于中、低精度的惯性测量单元(Inertial Measurement Unit, IMU)和中、低动态的 GNSS 接收机,致力于在维持较低成本的基础上改善单一系统的导航解。

国外对两个系统的耦合研究开始较早,其产品已经批量生产,美国等北约国家将其使用在军用飞机上,取得了预期的效果<sup>[3]</sup>。早在 1995 年,惯性导航和卫星导航集成 GPS/INS 技术就和捷联技术、计算技术一起,成为 INS 系统级技术 30 年来的主要贡献<sup>[4]</sup>。1989 年 6 月美国 McDonnell Douglas 导弹系统部的服务空对地导弹 SLAM 的紧耦合制导系统就采用了 SINS 辅助 GPS 接收机,即 Rockwell-Collins 提供的单通道序贯 P 码接收机,成功进行了三次实弹飞行试验<sup>[3]</sup>。除此之外,还有美军拉菲特级导弹核潜艇上装载的组合导航系统,法国海军使用的 SAGEM 组导系统、德国的 NACDS25 组合导航系统和 F-122 护卫舰用的 INA 组合导航系统、以及加拿大的基于 17 维状态扩展卡尔曼滤波的组合导航系统<sup>[5]</sup>。上世纪 80 年代开始,一些主要的惯导厂家和无线电制造公司加入研制 GPS/INS 组合导航系统的行列。1985 年, Honeywell 公司与 Stanford 公司合作,开始研制商业领域的组合系统。1986 年至 1987 年,在 Honeywell 公司、波音公司、Aerospatial 公司的联合飞行试验中,组合导航达到了很好的效果。2004 年,美军和北约军用飞机的主要导航设备从单独的机上 GPS 接收机改进为 EGI,即一种“嵌入 GPS 接收机的惯导系统”设备<sup>[6]</sup>。

国内对 GNSS/INS 组合导航系统的研究起步较晚,直到上个世纪 90 年代才开始对其的研究,目前仍然处于理论研究和验证阶段。虽然还有很多理论上和技术上的问题等待解决,不过国内有很多研究机构 and 高校在这个领域进行深入的研

---

究，并且也取得的初步的研究成果。国内的专家学者在 GNSS/INS 组合导航系统的几大关键问题，误差估值问题、Kalman 滤波技术、系统建模及精度分析、精度补偿技术，上都取的研究成果，这些专家学者来自北京航空航天大学、南京航空航天大学、国防科技大学及西北工业大学<sup>[5]</sup>。

GNSS/INS 集成技术有不同的组合方式，最简单是将两个子系统独立使用，两者互相作为另一方的备份。比较理想的组合方式是 1986 年 Buechler<sup>[7]</sup>提出的一体化组合，这个在硬件层组合的系统中卫星导航为惯性导航系统修正系统性误差，INS 辅助卫星导航接收机的跟踪环从而达到减小跟踪带宽、缩短卫星捕获时间、增加抗干扰能力和剔除多路径效应等效果。整个组合系统的体积、重量和功耗都被大幅降低了。

GNSS/INS 更为常见的组合方式是软件层的组合，两个子系统保持其各自的硬件系统相互独立，这种组合方式在工程中更容易实现，所以得到了广泛的关注。而软件层的组合也由于其耦合深度的不同，分为不同的组合方式<sup>[8-9]</sup>。

其中最简单的同时也是最早使用的是松耦合方式，也是研究组合导航的研究者在研究组合方式之外内容时最常使用的耦合方式。在这个模式下，组合导航的两个子系统独立工作，他们各自输出的位置和速度信息输入滤波器进行处理从而得到更精确的导航解。一般情况下组合导航采用的是卡尔曼滤波器及其扩展形式，其输入数据是惯性导航系统和卫星导航系统两者输出数据之差，输出的是对 INS 的速度、位置、姿态以及惯性元件误差的最优估计。这些误差被反馈给 INS 从而完成对 INS 输出导航解的校正。如图 2-1 所示，这个组合模式的结构简单，比较容易实现，可以有效地提高系统的导航精度，而且使 INS 具有了动基座对准的能力<sup>[10]</sup>。



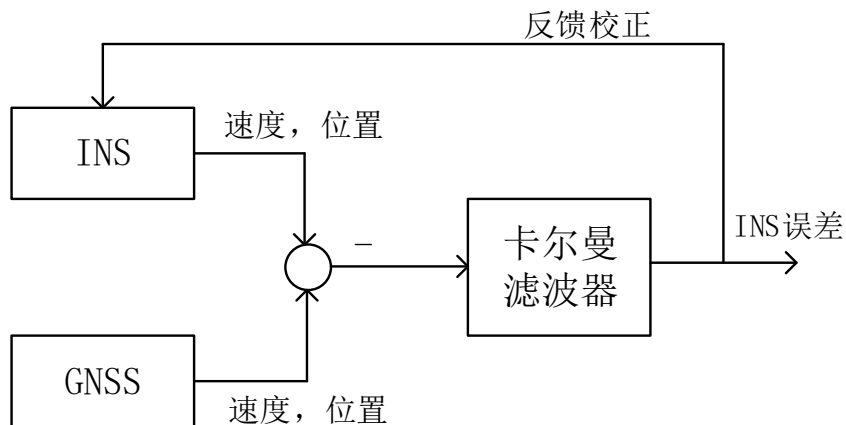


图 2-1 组合导航松耦合结构图

这种模式下如果卫星导航系统的接收机是通过自己的卡尔曼滤波器获得位置和速度信息的话，系统中会出现两级卡尔曼滤波器串联的现象，造成组合导航的观测噪声时间相关，导致其不满足卡尔曼滤波器观测噪声为白噪声的要求，因而造成误差加大。实际可以采用加大滤波器迭代周期来抵消影响。

紧耦合模式则较为复杂，其需要先通过卫星导航接收机接收到的星历信息和INS输出的位置和速度信息计算出导航载体当前处于INS输出状态的伪距和伪距率，再将计算出的伪距和伪距率与卫星导航测量出的伪距和伪距率一起输入到卡尔曼滤波器中，从而解出INS的误差来校正其输出数据，得到更精确的导航解<sup>[11-13]</sup>。这个模式在1990年左右就在国外得到了系统的研究实验，并且在1997年开始应用，比较多用于军事领域。如图2-2所示，这种模式下不存在卡尔曼滤波器的串联问题，能够达到更好的导航精度，并且可以在卫星导航系统的可见卫星不足4颗的情况下应用。

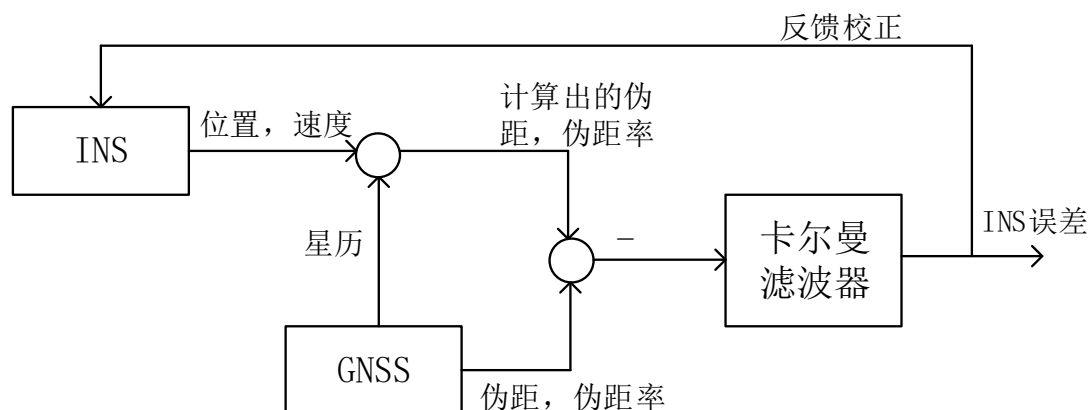


图 2-2 组合导航紧耦合结构图

超紧耦合模式是 Draper 实验室 Gustafson 等人在 2000 年明确提出的一种组合方式，是一种扩展范围码跟踪环的 GPS/INS 超紧耦合方法，能够提高接收机的抗干扰能力，并且他们采用仿真的 GPS 射频和惯导数据验证了这一方法的可行性<sup>[14]</sup>。其是一种比松耦合和紧耦合更复杂的组合方式，图 2-3 是超紧耦合的一种结构图，其不仅需要完成前两种组合方式的处理工作，同时也使用校正后的 INS 速度信息对卫星导航接收机的载波环和码环进行跟踪，使得 GNSS 接收机从信道和 INS 信息中校正多普勒频移带来的误差，从而减少环路的等效带宽，使得 GNSS 接收机在高动态环境和强干扰状态下的可靠性提升。美国的斯坦福大学和明尼苏达大学对于 INS 辅助 GPS 接收机载波跟踪环路研究工作比较深入。如美国的斯坦福大学的 Santiago Alban 和 Minnesota 大学的 Demoz Gebre 等人对超紧耦合下的 MEMS-IMU（微机电系统-惯性测量器件）辅助 GPS 的跟踪捕获回路进行了分析和研究，认为在低成本的 IMU（惯性测量器件）辅助下，接收机的搜索带宽可由传统的 15Hz 减小到 3Hz，增强了抑制噪声的能力<sup>[15]</sup>。同时，从事导航产业的几大公司，如美国 L3 IEC 公司、雷神公司等，也都建立了各自基于 GPS/INS 的超紧耦合耦合导航测试平台和系统。

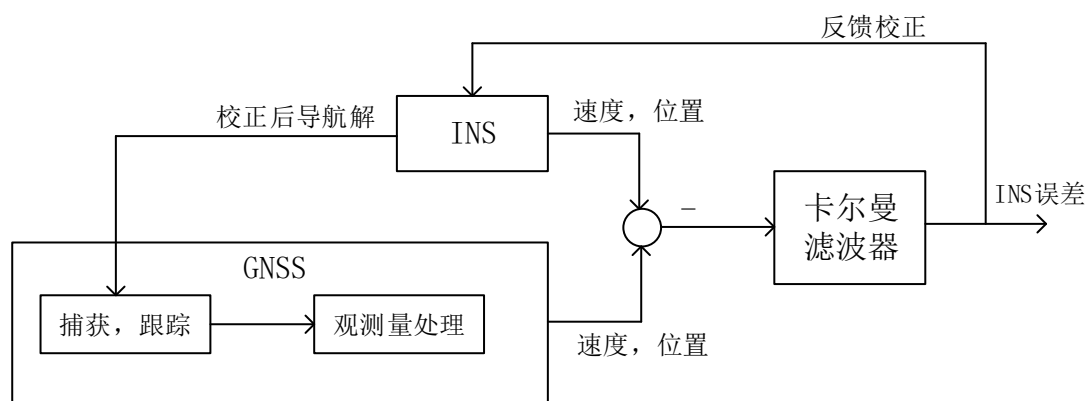


图 2-3 组合导航超紧耦合结构图

这种模式下 INS 信息辅助信道相关器捕获，能够获得更好的信号失锁后再捕能力，并且 INS 信息辅助抑制噪声和误差提供了更好的导航精度。此外，使用超紧耦合的组合导航系统对多径效应也有较好的抑制和校正作用。但是，由于

---

超紧耦合需要深入到接收机内部,有时甚至涉及到 GNSS 接收机内部码环、载波环电路的重新编排,其结构和算法比前两种组合方式更加复杂,但其随着数字计算机的发展,其正在成为现在组合导航领域的研究热点。

## 2.2 滤波技术研究现状

组合导航系统中很重要的一步是对来自不同子系统的数据进行融合,常用的方法就是滤波。滤波是从带有干扰的信号中准确估计出有用信号的值。而滤波理论则是依据一定的滤波准则,在对系统可观测信号进行测量后,采用某种统计最优的方法对系统的状态进行估计的理论和方法。而在组合导航系统中最为有效且简单的是卡尔曼滤波,卡尔曼滤波技术发展于 20 世纪 60 年代,在导航系统中有卓有成效的应用。

1960 年,卡尔曼(R. E. Kalman)发表了用递归方法解决离散数据线性滤波问题的文章,提出了卡尔曼滤波(Kalman Filtering, KF)法<sup>[16]</sup>。其是一种时域方法,对于具有高斯分布噪声的线性系统,可以得到系统状态的递推最小均方差估计。该方法将状态空间模型引入最优滤波理论,用状态方程描述动力学系统的状态空间转移模型,用观测方程描述动力学的系统观测模型。由于卡尔曼滤波算法采用递推方法,因而其计算过程能够用计算机实现。但同时卡尔曼滤波需要知道系统的精确数学模型,并假设系统为线性的,噪声信号也必须为噪声统计特性已知的高斯噪声,并且由于要计算 Diccati 方程,对高维系统计算量较大。

由于实际工程上的系统常常是非线性的,难以直接使用卡尔曼滤波器进行计算,为了克服这个问题,Bucy 和 Subahara 等人将非线性系统线性化再进行卡尔曼滤波,提出了扩展卡尔曼滤波(Extended Kalman Filtering, EKF)<sup>[17-18]</sup>。这是一种次优滤波方法,为了减小线性化带来的误差,考虑泰勒级数展开二次项的二阶滤波方法被提出<sup>[19]</sup>,但由于其带来了计算量上的增加,反而没有普通 EKF 使用广泛。

Biemran, carlson 及 schmidt 等人提出了平方根滤波算法和 UDU 分解滤波算法则是通过确保滤波方差矩阵正定来解决由于计算机舍入误差导致的计算发

---

散<sup>[20-21]</sup>。

高维系统卡尔曼滤波的计算量以状态维数的三次方剧增,往往难以满足实时性要求。为了解决这一问题和卡尔曼滤波同时存在的容错性差缺点, Speyer, Bierman, Kerr 等人在 1979 到 1985 年间先后提出了分散滤波的思想<sup>[22-23]</sup>,而 1955 年 Carlson 另辟蹊径,提出的联邦滤波理论采用两级滤波结构的联邦滤波也大大提高了系统的容错能力<sup>[24]</sup>。

由于工作环境和使用条件的变化,实际工作中的传感器噪声统计特性往往具有不确定性,而卡尔曼滤波要求知道噪声的统计特性,这将导致卡尔曼滤波性能下降甚至发散。自适应滤波方法就是为了克服这个缺点而发展起来。1969 年 Sage 和 Husa 提出了极大后验 (MAP) 估计<sup>[25]</sup>, 1978 年 Yoshimura 提出了虚拟噪声补偿<sup>[26]</sup>, 1969 年 Firedland 提出了动态偏差去耦估计<sup>[27]</sup>, 这些方法在一定程度上提高了卡尔曼滤波对噪声的鲁棒性。为了抑止由于模型不准确导致的滤波发散, 1969 年 Jazwisnik 提出有限记忆滤波方法<sup>[28]</sup>, 1971 年 Sorenson 提出衰减记忆滤波方法<sup>[29-30]</sup>。人工智能技术与滤波理论相结合,产生了一种新的自适应扩展卡尔曼滤波方法<sup>[31-32]</sup>,这种方法通过人工神经网络的在线训练,有效抑止了系统未建模动态特性的影响,使得滤波器也具有一定的鲁棒性。同时,一些利用滤波过程中的新息序列的自适应滤波方法也发展起来,这些自适应滤波方法根据新息序列的统计特性,对滤波器进行在线的评估、修正和改进,以降低滤波误差并增强滤波器适应变化的能力,从而使滤波器具有一定的鲁棒性。2011 年梁勇等人提出了简化的自适应卡尔曼滤波算法,减小了系统计算量的难题,并保证了导航的实时性<sup>[33]</sup>。很多其他滤波方法也被设计来减少计算量<sup>[34-36]</sup>。

鲁棒滤波方法提供了另一种新的思路针对卡尔曼滤波方法要求模型及信号统计特性必须准确这一问题<sup>[37-39]</sup>。 $H^\infty$  滤波方法是鲁棒滤波方法中发展较快的一种,该方法以牺牲滤波器的平均估计精度为代价,来保证滤波器对系统模型及外部干扰的鲁棒性能。也就是说,卡尔曼滤波方法保证了滤波器的平均估计性能最优,而  $H^\infty$  滤波方法则保证了滤波器在最坏情况下的滤波性能。 $H^\infty / H^2$  滤波理论则研究如何更好地平衡这两种方法的性能,即在保证滤波鲁棒性的同时,如

---

何进一步提高滤波器的其他性能，特别是平均性能最佳。

与对非线性函数的近似相比，对高斯分布的近似要简单的多。基于这种思想，Julier 和 Uhlmann 发展了 UKF (Unscented Kalman Filter, UKF) 方法<sup>[40-41]</sup>。UKF 方法直接使用系统的非线性模型，不像 EKF 方法那样需要对非线性系统线性化，也不需要如一些二次滤波方法那样计算 Jacobian 或者 Hessians 矩阵，且具有和 EKF 方法相同的算法结构。对于线性系统，UKF 和 EKF 具有同样的估计性能，但对于非线性系统，UKF 方法则可以得到更好的估计。

将 UKF 方法引入到非线性模型的参数估计和双估计中，Merwe 提出了 UKF 方法的方根滤波算法，该算法在大大减少了实际的计算量的同时确保了滤波的计算稳定<sup>[42]</sup>。

粒子滤波 (Particle Filter, PF) 在计算机计算能力的快速增长和计算成本的不断降低的今天已经成为研究非线性、非高斯动态系统最优估计问题的一个热点和有效方法。该方法实际上是使用蒙特卡罗仿真(Monte Carlo Simulation)来完成一个递推贝叶斯滤波(Recursive Bayesian Filter)，其核心是使用一个具有相应权值的随机样本集合(粒子)来表示需要的后验密度。

这些非线性滤波算法的提出丰富了非线性系统滤波算法理论，补充了卡尔曼滤波的不足之处，进一步完善了非线性系统领域的滤波算法研究。目前非线性滤波算法已经具有较高的稳定性，运算量适中，并在各种实际工程中得到充分应用。组合导航系统可能存在系统误差模型未知或噪声统计特性不匹配的情况，造成滤波结果不佳，设计一个适合组合导航系统的自适应滤波方法十分必要。随后学者相继提出了多种自适应滤波算法，常见的自适应滤波算法有：Sage-Huga 滤波<sup>[25]</sup>、渐消滤波<sup>[44]</sup>、抗差自适应滤波<sup>[45]</sup>、模糊自适应卡尔曼滤波<sup>[46]</sup>、强跟踪滤波<sup>[47]</sup>等算法。

## 2.3 滤波理论在组合导航中的应用

自从卡尔曼滤波器提出以来，将其运用于组合导航的研究一直在不断进行。最开始人们大多在 GNSS/INS 组合导航系统使用标准的卡尔曼滤波器，但在实际

---

使用中人们发现标准卡尔曼滤波器需要研究者精确了解外部量测噪声的统计规律,然而由于各种随机或复杂的误差源,如可见卫星数目、多路径效应和仪器内部的量测噪声等多种因素的影响,卫星导航系统的量测噪声会随时发生变化,而使用标准卡尔曼滤波器无法对上述的变化进行检测和调整,从而出现严重的估计偏差。为了克服标准卡尔曼滤波在组合导航应用中的缺点,研究者开始针对其设计与应用场景相适应的滤波算法。

卞鸿巍提出一种在线新息自适应调整卡尔曼增益阵的方法,可以通过实际新息的测量计算直接修正卡尔曼滤波器增益,提高了在 GPS 测量发生较大变化时卡尔曼滤波器的滤波精度和鲁棒性<sup>[48]</sup>。付梦印提出一种相关法自适应滤波和一种 Sage-Husa 自适应卡尔曼滤波应用于惯性技术领域<sup>[49]</sup>。高为广和杨元喜提出了一种神经网络辅助的 GPS/INS 组合导航自适应滤波算法,该算法利用神经网络对自适应滤波器状态方程的预报值进行在线修正,给出神经网络辅助的 GPS/INS 组合导航自适应滤波算法,该算法在滤波精度和可靠性方面有明显的提高<sup>[50]</sup>。Narasimhappa 等人提出了对 Sage-Husa 自适应鲁棒卡尔曼滤波算法的优化,更新了自适应比例因子的计算方法,能有效降低估计误差的平均值和标准差<sup>[51]</sup>。Hosseinyalamdary 提出一种使用递归神经网络来训练组合导航观测模型的方法,从而克服由 INS 误差模型的复杂性导致的滤波器误差<sup>[52]</sup>。

### 3. 课题的主要研究内容和预期目标

#### 3.1 研究内容

##### (1) 不同无人机 GNSS/INS 算法研究、总结与分析

GNSS/INS 组合导航系统能充分利用子系统的性能,提高无人机导航的精度和可靠性。通过对国内外的文献调研,研究、总结并分析各种无人机 GNSS/INS 算法,并且比较它们在精度和计算量上的差异。

##### (2) 基于深度卡尔曼滤波的 GNSS/INS 算法研究

深度卡尔曼滤波(Deep Kalman Filter, DKF)是一种在传统卡尔曼滤波中添

加建模过程的一种算法,其在训练过程使用机器学习算法对组合导航系统进行建模,在应用中使用建立好的模型进行导航解算,得到精确的速度、位置信息。深度卡尔曼滤波可以采用不同的机器学习建模方法和滤波算法实现。

为了简化计算，我们假设当前系统状态只依赖于当前隐变量，而当前隐变量依赖过去的隐变量和系统状态。则系统的概率图模型如图 3-1 所示。图 3-1 上层模型与经典卡尔曼滤波一致， $F$  表征系统模型的一步转移矩阵， $G$  表征量测系统的量测矩阵， $x$  为状态矩阵，在 GNSS/INS 中是我们想要知道的误差， $z$  为量测值，在 GNSS/INS 中是 GNSS 测量的导航数据。图 3-1 的下层模型是我们训练的模型， $W$  是待训练的参数矩阵， $h$  为隐藏层的隐变量。

图 3-1 深度卡尔曼滤波的概率图模型

### (3) 基于深度卡尔曼滤波的 GNSS/INS 算法实现

---

集中包含很多传感器带有标签的数据，我们使用数据集中 IMU 和 GPS 的数据。

结合 KITTI 数据集的数据，实现（2）中提出的 GNSS/INS 算法，分析实验结果并对算法进行优化。并且本实验室计划搭建组合导航物理平台，本课题算法可以在其上实现现场验证。

## 3.2 预期目标

针对以上实验内容，本课题的预期目标具体如下：

（1）学习不同的无人机 GNSS/INS 算法，比较不同算法的精度和计算量。

（2）提出基于 DKF 的 GNSS/INS 算法，使用不同的滤波算法和机器学习方法来设计 DKF 算法，比较这些算法在无人机场景中的精度和计算量，选取最适用于无人机导航的算法。

（3）基于开源数据集 KITTI 中 IMU 和 GPS 数据对算法进行实现，将结果与其他无人机导航算法比较，寻找算法的改进方向并进行优化。在实验室搭建的无人机平台上实现基于 DKF 的 GNSS/INS 算法，分析其实际精度和计算量，并进行算法优化。

## 4. 拟采用的研究方法 with 实验方案、技术路线、可行性分析

### 4.1 研究方法 with 实验方案

DKF 包含卡尔曼滤波和机器学习建模两个部分。

#### 1. 卡尔曼滤波

卡尔曼滤波估计的未知量为状态向量，表示为  $x \in \mathbb{R}^n$ ，其是一个时间变量，即  $x_t$  表示时刻  $t$  的状态向量。状态向量与过去直到现在观测矢量  $z_{1:t}$  相关，其中观测矢量  $z \in \mathbb{R}^m$ 。设初始状态为  $x_0$ ，则当前时刻处于状态  $x_t$  的概率是  $\Pr(x_t | z_{1:t}, x_0)$ 。根据极大似然估计（Maximum Likelihood Estimation, MLE），



$$\hat{x}_t = \arg \max_{x_t} \Pr(x_t | z_{1:t}, x_0) \quad (4-1)$$

系统当前的状态与过去的状态有关，即

$$\hat{x}_t = \arg \max_{x_t} \frac{\Pr(z_t | x_t) \Pr(x_t | z_{1:t-1}, x_0)}{\Pr(z_{1:t})} \quad (4-2)$$

上式中的分子是一个常数，在里面起到归一化作用，对极大似然估计的结果没有影响，所以

$$\hat{x}_t = \arg \max_{x_t} \Pr(z_t | x_t) \Pr(x_t | z_{1:t-1}, x_0) \quad (4-3)$$

由于系统的当前状态直接依赖于过去的状态，所以可以应用前一个状态向量的边缘化得到基于前一个状态向量的状态向量估计，即

$$\hat{x}_t = \arg \max_{x_t} \Pr(z_t | x_t) \int \Pr(x_t | x_{t-1}) \Pr(x_{t-1} | z_{1:t-1}, x_0) dx_{t-1} \quad (4-4)$$

基于马尔科夫假设，系统的当前状态只和上一时刻的系统状态相关，与之前的系统状态无关，即

$$\hat{x}_t = \arg \max_{x_t} \Pr(z_t | x_t) \int \Pr(x_t | x_{t-1}) \Pr(x_{t-1} | z_{1:t-1}, x_0) dx_{t-1} \quad (4-5)$$

上式中  $\Pr(z_t | x_t)$  是系统当前状态的后验概率，而上一时刻系统状态的最优估计为  $\hat{x}_{t-1} = \arg \max_{x_{t-1}} \Pr(x_{t-1} | z_{1:t-1}, x_0)$ ，所以

$$\hat{x}_t = \arg \max_{x_t} \Pr(z_t | x_t) \int \Pr(x_t | x_{t-1}) \hat{x}_{t-1} dx_{t-1} \quad (4-6)$$

式中  $\int \Pr(x_t | x_{t-1}) \hat{x}_{t-1} dx_{t-1}$  为先验概率。上式表示可以基于系统模型和过去时刻状态向量的后验估计预测当前状态向量。

在卡尔曼滤波器中，系统状态与上一时刻的状态和系统模型有关，即

$$x_t = f(x_{t-1}) + \varepsilon_t \quad (4-7)$$

式中  $\varepsilon_t$  是系统噪声模型。同时系统状态通过观测方程  $g$  映射到观测量  $z_t \in \mathbb{R}^m$ ，即

$$z_t = g(x_t) + \omega_t \quad (4-8)$$

式中  $\omega_t$  为观测噪声模型。在卡尔曼滤波中，状态模型和观测模型都是线性

的。因此，这些函数可以分别用  $F$  和  $G$  矩阵代替。系统模型可以改写为：

$$x_t = Fx_{t-1} + \varepsilon_t \quad (4-9)$$

同理，观测模型改写为：

$$z_t = Gx_t + \omega_t \quad (4-10)$$

假设卡尔曼滤波中系统噪声和观测噪声都是正态分布，即：

$$\varepsilon_t \sim N(0, Q_t) \quad (4-11)$$

$$\omega_t \sim N(0, R_t) \quad (4-12)$$

上面两个式子中的  $Q_t$  和  $R_t$  分别是系统噪声和观测噪声的协方差矩阵。

卡尔曼滤波过程分为两步：预测和更新。在第一步中，系统的当前状态由前一时刻状态预测，即：

$$x_t^- = Fx_{t-1}^+ \quad (4-13)$$

状态向量上的上标“-”表示预测量，上标“+”表示更新量。采用误差传播法，根据前一时刻状态向量的协方差矩阵估计当前状态向量的协方差矩阵，

$$P_t^- = FP_{t-1}^+ F^T + Q_t \quad (4-14)$$

式中  $P_t^-$  是当前状态的协方差矩阵的预测值。

在第二步更新过程中，当前状态的更新值由当前观测值和预测值得出，

$$x_t^+ = x_t^- + K_t (z_t - Gx_t^-) \quad (4-15)$$

则状态变量更新值的协方差矩阵为

$$P_t^+ = (I - K_t G) P_t^- (I - K_t G)^T + K_t R_t K_t^T \quad (4-16)$$

式中  $K_t$  是卡尔曼增益，其计算方法如下：

$$K_t = P_t^- G^T (G P_t^- G^T + R_t)^{-1} \quad (4-17)$$

卡尔曼滤波的过程如图 4-1 所示。




图 4-1 卡尔曼滤波过程

卡尔曼滤波器有许多缺点。由于要求  $F$  和  $G$  是带有高斯噪声的线性模型，卡尔曼滤波不能对非线性函数或带有非高斯噪声的线性函数进行建模。此外，卡尔曼滤波中的函数是时不变的，不会随时间变化。卡尔曼滤波器的一些扩展模式，像 EKF 和 UKF，可以处理非线性观测和系统模型。除此之外，粒子滤波还可以对非高斯分布的观测和系统进行建模。

然而，卡尔曼滤波及其扩展形式的观测和系统模型需要事先知道，即研究者应该找到将状态向量与前一时刻状态向量和观测联系起来的模型。然而，许多应用的观测和系统模型不能预先确定。

贝叶斯滤波器的另一个缺点是马尔可夫假设，即假设当前状态向量只依赖于前一时刻状态向量，独立于其他状态向量。虽然这个假设简化了系统模型，使滤波过程变得高效，但其也使滤波器对系统行为不敏感，相关性时间更长。所以具有较长的相关时间的复杂误差模型不能用贝叶斯滤波器建模。

由于 IMU 的加速度计和陀螺仪中的应用技术不同，IMU 模型具有不同的误差源。此外，即使在一个 MEMS 系列中，MEMS 传感器的误差源也可能明显不同于另一个 MEMS 传感器。所以，预定义的 IMU 误差模型无法处理 MEMS 传感器中误差源的高动态变化。与此同时，不同 MEMS 误差源间的可能存在的高度相关性也使得 IMU 误差建模非常复杂。并且再通常情况下，MEMS 传感器中的误差源不可区分。

## 2. DKF 算法

深度卡尔曼滤波在卡尔曼滤波中添加建模步骤。为了估计卡尔曼滤波器的系统模型，我们在卡尔曼滤波器中加入了隐变量，其在状态向量中不可见，但状态向量取决于隐变量。例如，IMU 误差依赖于温度，但温度在误差中不可见，也无法估计。隐变量用  $h_t$  表示，其随时间变化。当前系统状态取决于过去  $T$  个时刻

隐变量的值，即  $h_{t-1:t-T}$ 。

假设当天系统状态只与当前隐变量有关，即当前系统状态不直接依赖于过去系统状态  $x_{t-1:t-T}$ ，马尔科夫假设不在成立。我们设计的网络构架基于当前系统状态依赖于当前隐变量，而当前隐变量依赖过去的隐变量和系统状态。这个假设不仅符合很多不同的系统，而且简化了计算。

设当前隐变量与过去隐变量和系统状态之间的映射关系为  $\phi$ ，即

$$h_t = \phi(x_{t-1:t-T}^+, h_{t-1:t-T}) \quad (4-18)$$

当前系统状态直接与当前隐变量相关，

$$x_t^{+-} = \lambda(h_t) + \mu_t \quad (4-19)$$

式中  $x_t^{+-}$  为模型的后验估计。我们可以将函数  $\phi$  和  $\lambda$  近似为一个线性函数和一个非线性函数的组合，其中线性函数可以用矩阵乘法表示，即线性函数的参数可以用参数矩阵  $W$  表示；非线性函数  $\sigma$  没有参数。所以，待求解网络可表示为：

$$h_t = \sigma(W_{xh}x_{t-1:t-T}^+, W_{hh}h_{t-1:t-T}) \quad (4-20)$$

$$x_t^{+-} = \sigma(W_{xx}h_t) + \mu_t \quad (4-21)$$

如上，隐函数的参数矩阵为  $W_h = [W_{xh}, W_{hh}]$ 。所以建模的任务转化为估计参数矩阵  $W_h$  和  $W_{xx}$ 。如图 4-1 和图 4-2 所示，深度卡尔曼滤波的上层网络与传统卡尔曼滤波基本一致，我们的建模步骤集中于下层网络中。




图 4-2 典型卡尔曼率的概率图模型

#### (1) EM 算法

当系统模型的参数未知时，系统模型和状态向量无法直接估计。此时，状态

向量取决于系统模型的隐变量。为了找到状态向量和隐向量，可以采用期望最大化方法（Expectation Maximization, EM）。EM 算法是一种估计隐变量和系统状态的迭代方法。首先假设隐变量的初始值猜测为  $h_t^{(0)}$ ，则基于初始隐变量猜测值的系统状态为

$$\hat{x}_t^{(1)} = \arg \max_{x_t} \Pr(x_t | h_t^{(0)}, z_{1:t}, x_0) \quad (4-22)$$

公式(4-1)是基于预先定义的系统模型，上式则获得基于猜测隐变量的系统状态。下一步则基于上式的结果估计隐变量，

$$\hat{h}_t^{(1)} = \arg \max_{h_t} \Pr(\hat{x}_t^{(1)} | h_t, z_{1:t}, x_0) \quad (2-23)$$

根据公式(4-21)，计算系统状态可以转化为计算参数矩阵  $W_{xx}$ ，同理，计算隐变量转化为计算参数矩阵  $W_h$ 。将式(4-20)和式(4-21)代入公式(4-22)，则

$$\hat{W}_{xx}^{(1)} = \arg \max_{W_{xx}} \Pr(x_t | h_t^{(0)}, z_{1:t}, x_0) \quad (4-24)$$

参数矩阵  $\hat{W}_{xx}^{(1)}$  估计后，则状态向量  $\hat{x}_t^{(1)}$  就可以被计算出来。公式(4-20)的状态矩阵估计公式为：

$$\hat{W}_h^{(1)} = \arg \max_{W_h} \Pr(\hat{x}_t^{(1)} | h_t, z_{1:t}, x_0) \quad (4-25)$$

隐变量和状态向量的迭代估计一直持续到算法收敛到其解，最后确定系统模型并得出状态向量的估计。Mirowski 和 LeCun 的研究表明 EM 算法可以使用递归神经网络训练<sup>[53]</sup>。

EM 算法最终收敛到凸函数的全局最大值，然而对于一些建模为非凸函数的系统，EM 很有可能收敛到局部极大值，所以如何找到公式(4-24)和公式(4-25)中的最大值是一个挑战。

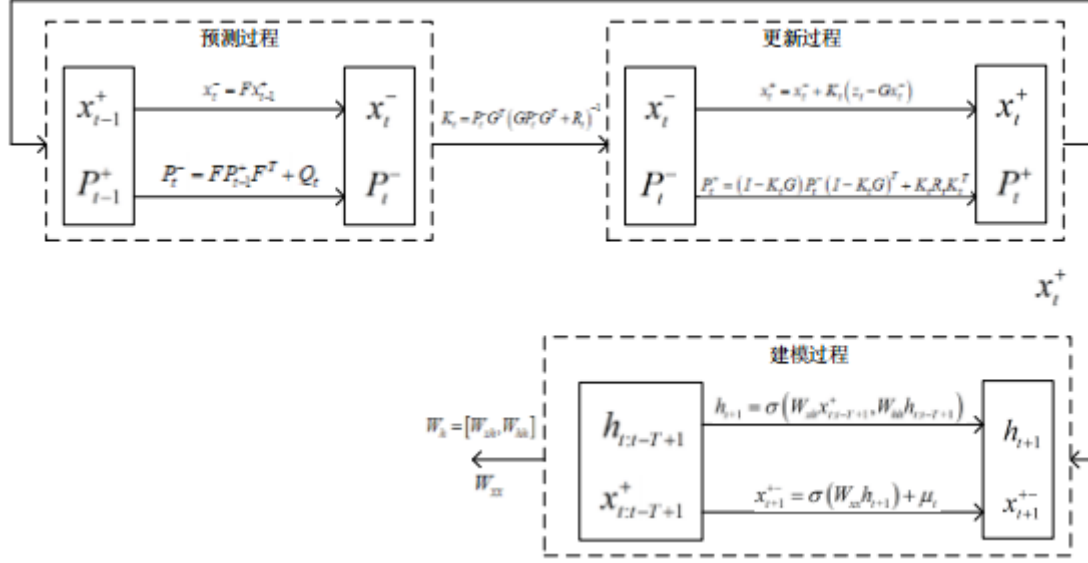


图 4-4 深度卡尔曼滤波的流程图

如图 4-4 所示，深度卡尔曼滤波的建模过程分为两步，第一步是通过过去的系统状态和隐变量估计当前隐变量，第二步是通过当前隐变量估计当前系统状态。

## (2) 递归神经网络 RNN

使用隐变量估计重新构造公式(4-6)，则

$$\hat{x}_t = \arg \max_{x_t} \Pr(z_t | x_t) \int \Pr(x_t | h_t) \Pr(h | h_{t-1:t-T}, x_{t-1:t-T}) \hat{x}_{t-1:t-T} dx_{t-1:t-T} \quad (4-26)$$

在 EM 算法的第一部分 E 中，我们依据猜测的模型和观测量计算  $\hat{x}_t$ 。在 GNSS/INS 组合导航系统中，我们使用卡尔曼滤波来估计系统状态  $x_t^+$ 。当 GNSS 观测量是精确的，则估计的系统状态也是精确的。在 EM 算法的第二部分 M 中，我们利用猜测的模型来计算系统状态，这个基于猜测模型的近似状态向量用  $x_t^{+-}$  来表示。如果我们的猜测模型是正确的，则近似状态向量  $x_t^{+-}$  应该与系统状态  $x_t^+$  相等或者十分接近。因此，我们可以用两者的差的能量函数  $E$  来衡量我们的模型的准确性，当其最小的时候我们的模型最准确。能量模型表示为：

$$E(W_h, W_{xx}) = \frac{1}{2} (x_t^{+-} - x_t^+)^2 \quad (4-27)$$

将(4-21)代入(4-26)，

$$E(W_h, W_{xx}) = \frac{1}{2} (\sigma(W_{xx} h_t) - x_t^+)^2 \quad (4-28)$$

则参数矩阵  $W_{xx}$  的梯度

$$\frac{\partial E(W_h, W_{xx})}{\partial W_{xx}} = \frac{\partial \sigma(W_{xx} h_t)}{\partial W_{xx}} (\sigma(W_{xx} h_t) - x_t^+) \quad (4-29)$$

参数矩阵  $W_h$  的梯度

$$\frac{\partial E(W_h, W_{xx})}{\partial W_h} = \frac{\partial \sigma(W_{xx} x_{t-1:t-T}^+ + W_{hh} h_{t-1:t-T})}{\partial W_h} \frac{\partial \sigma(W_{xx} h_t)}{\partial W_{xx}} (\sigma(W_{xx} h_t) - x_t^+) \quad (4-30)$$

为了使能量函数最小化，我们使用梯度下降方法。所以，建模系统的参数矩阵  $W_h$  和  $W_{xx}$  可以估计出来。

$$W_{xx}^{(m+1)} = -\frac{\partial E(W_h, W_{xx})}{\partial W_{xx}} \mu + W_{xx}^{(m)} \quad (4-31)$$

$$W_h^{(m+1)} = -\frac{\partial E(W_h, W_{xx})}{\partial W_h} \mu + W_h^{(m)} \quad (4-32)$$

上式中的参数  $\mu$  为学习参数。参数矩阵被确定后，网络模型也就学习好了，模型状态向量  $x_t^+$  可以从过去的状态向量  $x_{t-1:t-T}^+$  利用公式(4-31)和(4-32)计算出来。

### (3) 长短期记忆网络 LSTM

递归神经网络的劣势是梯度爆炸和梯度消失<sup>[53]</sup>。当  $T$  比较大且我们的建模时间较长时，梯度会在几层网络中做乘法运算，则较大的梯度导致乘积更大，最终达到梯度爆炸。反之，如果梯度较小，则乘积会趋近于零，从而导致梯度消失。为了抑制递归神经网络中的这种效应，LSTM 中采用了门记忆<sup>[54]</sup>。在 LSTM 中，其向递归神经网络中加入了判断信息是否有用的处理器——cell，一个 cell 当中被放置了三扇门，分别叫做输入门、遗忘门和输出门。用  $i_t$  表示输入门， $o_t$  表示输出门， $f_t$  表示遗忘门，这三种门都可以使用线性函数和非线性函数的组合来表示：

$$f_t = \sigma(W_f x_t + U_f h_{t-1}) \quad (4-33)$$

$$i_t = \sigma(W_i x_t + U_i h_{t-1}) \quad (4-33)$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1}) \quad (4-33)$$

式中  $\sigma$  表示非线性函数，线性函数由参数矩阵表示。处理器 cell 的状态  $c_t$  和隐藏层  $h_t$  计算：

$$c_t = f_t \circ c_{t-1} + i_t \circ \sigma(W_c x_t + U_c h_{t-1}) \quad (4-34)$$

$$h_t = o_t \circ \sigma(c_t) \quad (4-35)$$

式中  $\circ$  为 Hadamard 乘积。对于长期相关性，输入门可以保持以前状态向量的信息，并且可以访问以前状态向量的梯度。因此，梯度在反向传播过程中不会爆炸或消失。遗忘门控制了模型的复杂性，并删除了不相关的过去状态向量。

整个系统分为两个部分，即训练部分和应用部分。

我们已经知道的是：如果 GNSS 测量能够得到，将其作为量测值输入到扩展卡尔曼滤波器中，应用系统模型和观测模型来预测和更新系统状态；如果 GNSS 失锁或其他无法获得 GNSS 数据的情况，扩展卡尔曼滤波器只能完成预测过程。

则在训练部分在 GNSS 数据能够得到的时候进行，我们利用扩展卡尔曼滤波器的输出，即系统状态的后验估计  $x_t^+$  作为我们建模过程系统状态的真值。再使用深度卡尔曼滤波来预测系统状态  $x_t^-$ ，然后通过运算获得使两者充分接近的参数矩阵，如图 4-5 所示，从而建立好了模型。值得注意的是，我们的模型中不需要 GNSS 的数据。

应用部分则是在 GNSS 数据无法获得时，此时可以使用训练好的网络，如图 4-6 所示，来计算  $x_t^{+-}$ ，如果训练模型足够精确，则模型计算出的状态向量比扩展卡尔曼滤波器预测过程输出的状态变量  $x_t^-$  要精确。






图 4-5 DKF 训练网络结构图




图 4-6 DKF 应用网络结构图

## 4.2 技术路线

技术路线主要分为无人机导航算法调研，滤波和机器学习算法学习，DKF 算法研究与设计，基于开源数据集的算法测试和物理平台验证 5 个部分。其流程如图 4-7 所示。

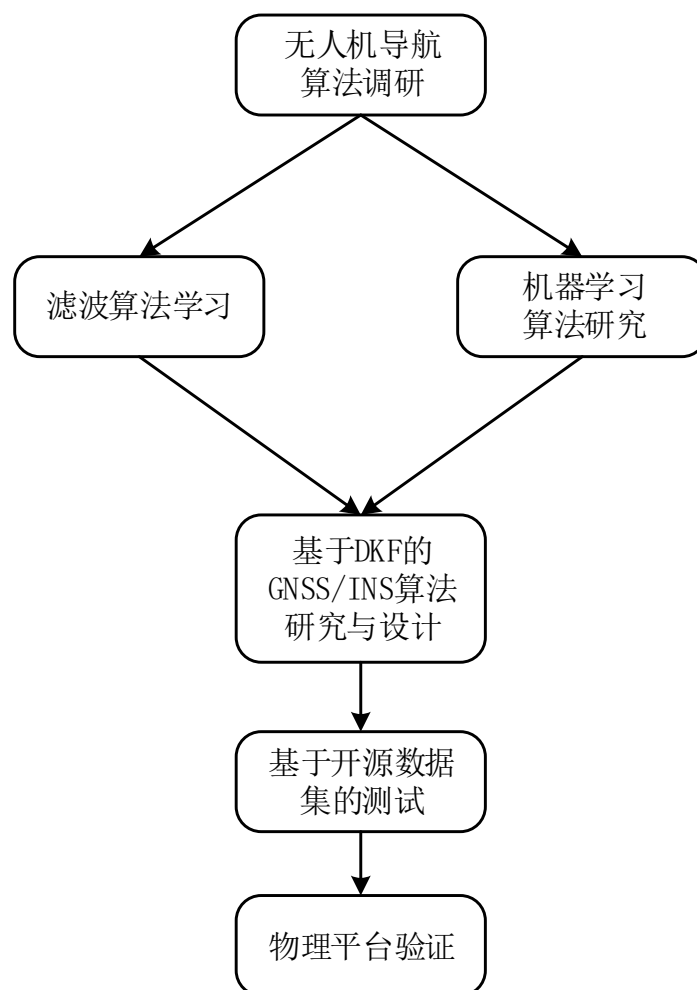


图 4-7 技术路线示意图

### 4.3 可行性分析

首先，GNSS/INS 组合导航系统早在上个世纪就投入研究，现在已经在各种场景中实现应用，在无人机上的应用研究也趋于成熟。其次，作为一种融合两种不同数据的方法，深度卡尔曼滤波已经被一些团队研究并且验证了其可行性。最后，本人所在的实验室在导航领域取得过重要的研究成果并且正在逐步架设无人机平台，这给课题提供了理论基础和实验平台。

综上所述，本课题的研究内容可行。

---

## 5. 已有科研基础与所需的科研条件

### 5.1 已有的科研基础

(1) 通过对无人机导航算法的调研，对无人机系统和组合导航的研究现状和主要理论有了一定的了解。

(2) 本人所在实验室在导航领域取得过工程和研究上的重要进展，对本人的学习有重要指导作用。

(3) 本人所在的实验室基于申请的项目正逐步搭建无人机组合导航系统平台，为课题的研究提供了条件和保障。

### 5.2 所需科研条件

(1) 计算机一台，用于算法的设计和实现。

(2) 开源数据集，用于对课题所提出的算法进行实验并优化。

(3) 无人机平台，用于对课题提出的算法进行实测验证。

## 6. 研究工作计划与进度安排

依据本课题的研究内容及技术路线，拟将课题分为三部分逐步完成。

第一部分：完成无人机导航算法的深入调研，学习滤波和机器学习的算法。

第二部分：完成基于 DKF 的 GNSS/INS 算法设计，比较不同算法在无人机任务中的精度及计算量。

第三部分：基于开源数据集和物理实验平台对提出的算法进行测试和验证，分析实验结果并优化算法。

根据课题的整个时间跨度，做出以下的时间安排：

2018 年 12 月——2019 年 3 月：完成第一部分的目标；

2019 年 3 月——2019 年 5 月：完成第二部分的目标；

2019 年 5 月——2019 年 11 月：完成第三部分的目标，并且完成小论文的撰

---

写、投稿；

2019 年 11 月：撰写中期报告，准备中期答辩；

2019 年 11 月——2010 年 4 月：撰写毕业论文，准备毕业答辩。

---

## 参考文献

- [1] 李鹏程. 组合导航及其滤波算法研究[D]. 西安电子科技大学, 2010.
- [2] 温武, 郭圣权. INS / GPS 组合导航集中式卡尔曼滤波器的仿真研究[J]. 导航, 2002 (4) :41-49.
- [3] 刘婧. GPS/INS 紧耦合组合导航系统研究[D]. 西安电子科技大学, 2010.
- [4] R. L . Inertial navigation technology from 1970-1995[J]. Navigation, 1995, 42 (1) :165-185.
- [5] 黄兵超. GPS/INS 组合导航系统研究[D]. 国防科学技术大学, 2010.
- [6] 张平. RDSS/GPS/SINS 组合导航系统仿真与研究[D].西北工业大学,2006.
- [7] Buechler D , Foss M . Integration of GPS and Strapdown Inertial Subsystems into a Single Unit[J]. Navigation, 1987, 34 (2) :140–159.
- [8] 艾伦, 金玲, 黄晓瑞. GPS/INS 组合导航技术的综述与展望[J]. 数字通信世界, 2011 (2) :58-61.
- [9] Knight D T . Achieving modularity with tightly-coupled GPS/INS[C]// IEEE Position Location & Navigation Symposium. IEEE, 1992.
- [10]Strunz H C . A New Algorithm for the Initial Alignment of Integrated INS/GPS Systems[J]. Ultrasound in Obstetrics & Gynecology, 2000, 22 (S1) :61–62.
- [11]Falco G, Pini M, Marucco G. Loose and Tight GNSS/INS Integrations: Comparison of Performance Assessed in Real Urban Scenarios:[J]. Sensors, 2017, 17 (2) :27.
- [12]Schwarz K P , Wei M , Van Gelderen M . Aided versus embedded-a comparison of two approaches to gps/ins integration[C]// Position Location & Navigation Symposium. IEEE, 1994.
- [13]黄凤钊, 彭允祥. GPS/SINS 伪距(伪距变化率)组合导航系统实验研究[J]. 中国惯性技术学报, 1998 (2) :1-9.
- [14]Dowdle J R, Elwell J J M, Gustafson D E. Deeply-integrated adaptive GPS-based

- 
- navigator with extended-range code tracking[C]// Position Location and Navigation Symposium, IEEE. IEEE, 2000:118-124.
- [15]Alban S . An Inexpensive and Robust GPS/INS Attitude System for Automobiles[J]. Proceedings of International Technical Meeting of the Satellite Division of the Institute of Navigation, 2002:1075-1087.
- [16]Kalman R E . A New Approach To Linear Filtering and Prediction Problems[J]. Journal of Basic Engineering Transactions, 1960.
- [17]Sunahara Y. An Approximate Method of State Estimation for Nonlinear Dynamical Systems[J]. International Journal of Control, 1970, 11(6):957-972.
- [18]R.S. Bucy, K.D. Senne. Digital synthesis of non-linear filters [J]. Automatica, 1970, 7(3):287-298.
- [19]史忠科. 最优估计的计算方法[M]. 科学出版社, 2001.
- [20]Bierman G J . Sequential square root filtering and smoothing of discrete linear systems[J]. Automatica, 1974, 10(2):147-158.
- [21]Schmidt S F . Computational Techniques in Kalman Filtering[J]. 1970.
- [22]Speyer J L. Computation and transmission requirements for a decentralized linear-quadratic-Gaussian control problem[C]// Decision and Control Including the, Symposium on Adaptive Processes, 1978 IEEE Conference on. IEEE, 1979:1126-1131.
- [23]Kerr T. Decentralized Filtering and Redundancy Management for Multisensor Navigation[J]. IEEE Transactions on Aerospace & Electronic Systems, 1987, aes-23(1):83-119.
- [24]Carlson N A. Federated square root filter for decentralized parallel processors[J]. Aerospace & Electronic Systems IEEE Transactions on, 1990, 26(3):517-525.
- [25]SAGE A P, HUSA G W. Adaptive filtering with unknown prior statistics[J]. JACC, 1969(1):760-769.
- [26]Yoshimura T , Soeda T . A Technique for Compensating the Filter Performance by a Fictitious Noise[J]. Journal of Dynamic Systems Measurement & Control,

- 
- 1978, 100(2):154-156.
- [27]Friedland B. Treatment of bias in recursive filtering[J]. IEEE Transactions on Automatic Control, 2003, 14(4):359-367.
- [28]Jazwinski, AndrewH. Stochastic processes and filtering theory[M]. Academic Press, 1970.
- [29]Sorenson HW. Comment on ‘A practical non-diverging filter’, AIAA Journal,1970,9,767.
- [30]张金槐. 自适应衰减记忆滤波 [J]. 国防科技大学学报, 1993(3).
- [31]史忠科. 神经网络控制理论[M]. 西北工业大学出版社, 1997.
- [32]吴美平. 陆用激光陀螺捷惯导系统误差补偿技术研究[D]. 国防科学技术大学, 2000.
- [33]梁勇, 李瑞涛, 张友安, et al. 一种新的组合导航系统自适应信息融合方法 [C]// 中国自动化学会控制理论专业委员会 c 卷. 2011.
- [34]Wang Q , Cui X , Li Y , et al. Performance Enhancement of a USV INS/CNS/DVL Integration Navigation System Based on an Adaptive Information Sharing Factor Federated Filter[J]. Sensors, 2017, 17(2):239.
- [35]Bergman N , Ljung L , Gustafsson F . Terrain navigation using Bayesian statistics[J]. IEEE Control Systems, 1999, 19(3):33-40.
- [36]Baier R , Gerdtz M , Xausa I . Approximation of reachable sets using optimal control algorithms[J]. Numerical Algebra, Control and Optimization (NACO), 2013, 3(3):519-548.
- [37]Shaked U.  $H_{\infty}$ -minimum error state estimation of linear stationary processes[J]. Automatic Control IEEE Transactions on, 1990, 35(5):554-558.
- [38]Rotstein H, Sznajder M, Idan M.  $H_2/H_{\infty}$  filtering: theory and an aerospace application[C]// American Control Conference. IEEE, 1994:1791-1795 vol.2.
- [39]Rotstein H, Sznajder M, Idan M.  $H_2/H_{\infty}$  filtering theory and an aerospace application[J]. International Journal of Robust & Nonlinear Control, 2015, 6(4):347-366.

- 
- [40]Julier S J , Uhlmann J K , Durrant-Whyte H F . A New Approach for Filtering Nonlinear Systems[C]// American Control Conference. IEEE, 1995.
- [41]Julier S, Uhlmann J, Durrantwhyte H F. A new method for nonlinear transformation of means and covariances in filters and estimates[J]. IEEE Trans.on Automat.contr, 2000, 45(3):477-482.
- [42]Merwe R V D, Wan E A. The square-root unscented Kalman filter for state and parameter-estimation[C]// IEEE International Conference on Acoustics, Speech, and Signal Processing, 2001. Proceedings. IEEE, 2002:3461-3464 vol.6.
- [43]Arulampalam M S, Maskell S, Gordon N, et al. A tutorial on particle filters for online nonlinear/non-Gaussian Bayesian tracking[J]. IEEE Transactions on Signal Processing, 2002, 50(2):174-188.
- [44]Fagin S.L. Recursive linear regression theory, optimal filter theory, and error analyses of optimal systems[J].IEEE IntConvent Record,1964(12):216-240.
- [45]Yang Y, He H, Xu G. Adaptively robust filtering for kinematic geodetic positioning[J]. Journal of Geodesy, 2001, 75(2-3):109-116.
- [46]徐田来, 游文虎, 崔平远. 基于模糊自适应卡尔曼滤波的 INS / GPS 组合导航系统算法研究[J]. 宇航学报, 2005, 26(5):571-575.
- [47]周东华, 席裕庚, 张钟俊. 一种带多重次优渐消因子的扩展卡尔曼滤波器[J]. 自动化学报, 1991, 17(06).
- [48]卞鸿巍. 现代信息融合技术在组合导航中的应用[M]. 国防工业出版社, 2010.
- [49]付梦印, 邓志红, 闫莉萍. Kalman 滤波理论及其在导航系统中的应用[M]. 科学出版社, 2010.
- [50]高为广. 神经网络辅助的 GPS/INS 组合导航自适应滤波算法[J]. 测绘学报, 2007, 36(1):26-30.
- [51]Narasimhappa M , Mahindrakar A D , Guizilini V C , et al. An improved Sage Husa adaptive robust Kalman Filter for de-noising the MEMS IMU drift signal[C]// Indian Control Conference. 2018.
- [52]Hosseinyalamdary S. Deep Kalman Filter: Simultaneous Multi-Sensor Integration



- 
- and Modelling; A GNSS/IMU Case Study[J]. Sensors, 2018, 18(5).
- [53]Goodfellow I, Bengio Y, Courville A. Deep Learning[M]. The MIT Press, 2016.
- [54]Jürgen Schmidhuber. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8):1735-1780.